Nama: Muhamad Feriyanto

Kelas : 3SD1

NIM : 222011347

Responsi Information Retrieval

Pertemuan 9

Language Model for Information Retrieval

Query = "vaksin corona jakarta"

Corpus = berita

Standard Query Likelihood

Top 3 Standard Query Likelihood

Rank Dokumen	Likelihood Score
Berita 3	1,76E-10
Berita 1	0,00
Berita 2	0,00

Dalam Standard Query Likelihood didapatkan rank 3 teratas pada dokumen 'Berita3', 'Berita1', dan 'Berita2'. Berita 3 memiliki likelihood score yang sangat kecil (mendekati 0), sedangkan berita lainnya likelihood scorenya adalah 0 ada metode Standard Query Likelihood.

Smoothing

Laplace Smoothing

Top 3 Laplace Smoothing

Rank Dokumen	Likelihood Laplace Score					
Berita 3	2.870317203059586E-06					
Berita 2	1.7176733341735618E-06					
Berita 4	1.017708121310808E-06					

Dengan menggunakan Laplace Smoothing, didapatkan rank 3 teratas pada dokumen 'Berita3', 'Berita2', dan 'Berita4' dengan nilai yang mendekati 0.

Jelinek-Mercer Smoothing

Top 3 Jelinek-Mercer Smoothing

```
In [76]: 1    rank_jm = exact_top_k_lm(no_sw, likelihood_scores_jm, 3)
2    for doc_id in rank_jm:
        print (f"{doc_id}: {rank_jm[doc_id]}")
```

berita3: 5.343605548663745e-06 berita2: 2.993721377858216e-06 berita4: 8.093859893072541e-07

Rank Dokumen	Likelihood Jelinek-Mercer Score
Berita 3	5.343605548663745e-06
Berita 2	2.993721377858216e-06
Berita 4	8.093859893072541e-07

Dengan menggunakan Jelinek-Mercer Smoothing, didapatkan rank 3 teratas pada dokumen 'Berita3', 'Berita2', dan 'Berita4' dengan nilai yang mendekati 0.

Dirichlet Smoothing

Top 3 Dirichlet Smoothing

```
In [75]: 1    rank_dir = exact_top_k_lm(no_sw, likelihood_scores_dir, 3)
2    for doc_id in rank_dir:
3         print (f"{doc_id}: {rank_dir[doc_id]}")
```

berita3: 1.6560809893382465e-05 berita2: 8.003647272632313e-07 berita5: 1.2052938144770354e-07

Rank Dokumen	Likelihood Jelinek-Mercer Score					
Berita 3	1.6560809893382465e-05					
Berita 2	8.003647272632313e-07					
Berita 5	1.2052938144770354e-07					

Dengan menggunakan Dirichlet Smoothing, didapatkan rank 3 teratas pada dokumen 'Berita3', 'Berita2', dan 'Berita5' dengan nilai yang mendekati 0.

Tambahan:

Okapi BM25

```
In [77]: from collections import OrderedDict
    def exact_top_k_bm25(doc_dict, rank_score, k):
        relevance_scores = {}
        i = 0
        for doc_id in doc_dict.keys():
        relevance_scores[doc_id] = rank_score[i]
        i = i + 1

# sorted_value = OrderedDict(sorted(relevance_scores.items(), key=lambda x: x[1], reverse = True))
        top_k = {j: sorted_value[j] for j in list(sorted_value)[:k]}

        sorted_value = OrderedDict(sorted(relevance_scores.items(), key = lambda x:x[1], reverse = True))
        top_k = {j: sorted_value[j] for j in list(sorted_value)[:k]}

In [80]: exact_top_k_bm25(no_sw, querinisasi("vaksin corona jakarta"), 3)

Out[80]: {'berita3': 1.068210132282897,
        'berita5': 0.8332116429494796,
        'berita5': 0.544069042444546}
```

VSM

```
In [114]: # Menyimpan skor kemiripan daLam suatu list
from collections import OrderedDict
def exact_top_k_vsm(doc_dict, TD, q,k):
    relevance_scores = {}
    i = 0
    for doc_id in doc_dict.keys():
        relevance_scores[doc_id] = cosine_sim(q, TD[:,i])
        i = i + 1

        sorted_value = OrderedDict(sorted(relevance_scores.items(),key = lambda x:x[1], reverse = True))
        top_k = {j : sorted_value[j] for j in list(sorted_value)[:k]}
        return top_k
        top_3_vsm = exact_top_k_vsm(no_sw, TD, TQ[:, 0], 3)
        print(top_3_vsm)

{'berita2': 0.9937562849886573, 'berita3': 0.9932276247792821, 'berita1': 0.9918235081246563}
```

Tabel perbandingan

VSM, Okapi BM25, Standard Query Likelihood, Laplace Smoothing, Jelinek-Mercer Smoothing, Dirichlet Smoothing

Rank	Okapi BM25		VSM		Likelihood		Laplace		JM		Dirichlet	
	Doc	Nilai	Doc	Nilai	Doc	Nilai	Doc	Nilai	Doc	Nilai	Doc	Nilai
1	Berita3	1,0682	Berita2	0,9938	Berita3	1,76e-10	Berita3	2,87e-06	Berita3	5,34e-06	Berita3	1,65e-05
2	Berita2	0,8332	Berita3	0,9932	Berita1	0,00	Berita2	1,71e-06	Berita2	2,99e-06	Berita2	8,00e-07
3	Berita5	0,5441	Berita1	0,9918	Berita2	0,00	Berita4	1,01e-06	Berita4	8,09e-07	Berita5	1,21e-07

Kesimpulan:

Dalam beberapa metode yang telah diterapkan, terdapat perbedaan dalam dokumen yang di-retrieve.